## 大规模分布式系统第六次作业报告

首先要将表放入 HDFS 中,故先为表创建了 table1.csv 和 table2.csv 文件。 在 Hadoop 下创建输入文件夹

```
hadoop@ubuntu:/usr/local/Hadoop/bin$ ./hadoop fs -ls /input
```

将本地两个文件全部放入 input 文件夹下,然后观察 input 文件夹下的文件,发现已经成功执行

```
hadoop@ubuntu:/usr/local/Hadoop/bin$ ./hadoop fs -ls /input
Found 2 items
-rw-r--r-- 1 hadoop supergroup 146 2019-06-10 08:22 /input/table1.csv
-rw-r--r-- 1 hadoop supergroup 137 2019-06-10 08:22 /input/table2.csv
```

现在打开 pyspark,在 jupternotebook 的运行环境下进行运行测试是否能够成功 读入 HDFS 的文件。

## 验证成功

为了适应虚拟机的环境,现在将表的列全部改为英文,便于处理。 对两个表的数据导入进行观察。

```
data1 = sqlContext.read.format("com.databricks.spark.csv").options(header='true',inferschema='true').load("hdfs://localhos
data1.show()
|number|chinese|math|
               56
74
                    68
88
    102
    103
    104
105
              36 |
88 |
                    75
44
              65 |
44 |
    106
107
                    78
99
              78
60
                     65
76
    108
    109
                     47
    111
              54
                     88
```

为了解决题目中的问题,我决定在 pyspark 中使用 sql 语句进行操作。 首先要将读入的数据注册成表。

男性数学及格的同学中最高身高同学的学号

高于170的女性同学的平均总分

## 男性同学平均总分

```
In [13]: result1 = sqlContext.sql("""select avg(math)+avg(chinese) from table1 join table2 on table1.number = table2.number where so

In [14]: result1.show()

| (avg(math) + avg(chinese))|
| 132.1666666666669|
```

## 女性同学平均总分